金融大数据处理技术 作业 1

姓名： 李柏糠
学号： 241275026

1. 请简要介绍科学研究的第四范式

科学研究经历了四种范式：实验科学、理论科学、计算科学和数据科学。第四范式即**数据科学（数据密集型科学发现）**。它以海量、多源数据为研究对象，综合科学实验、理论模型或算法、计算机模拟与密集型数据处理，通过数据采集、存储、管理、分析和挖掘来发现规律、形成知识并支持决策。

与主要依靠观察实验、公式推导或计算机模拟的前三种范式相比，第四范式更强调从数据中发现问题和规律。计算机科学侧重研究算法，而数据科学侧重研究数据及其价值；二者结合，使复杂现象能够被更及时、更全面地认识。

2. 请简述结构化数据、半结构化数据、非结构化数据的区别

三者的主要区别在于是否具有固定的数据模式（Schema）、组织方式以及处理难度。

类型	主要特征	典型例子	常见处理方式
结构化数据	字段、类型和记录格式固定， 可按二维表的行、列组织， 便于直接查询和统计。	银行账户信息、交易流水、 债券收益率、 财务报表中的标准化指标。	关系数据库、 SQL、 统计分析。
半结构化数据	没有严格的二维表结构， 但带有标签、键值对或层次关系， 可从中识别部分结构。	JSON、XML、网页日志、 带元数据的邮件。	NoSQL 数据库、 解析程序、 ETL。
非结构化数据	没有预先定义的固定模式， 内容形式多样， 机器难以直接按字段检索和分析。	文本、新闻、客服录音、 图片、视频、 社交媒体内容。	自然语言处理、 图像/ 语音处理、 机器学习等。

因此，结构化程度越低，数据表达的信息通常越丰富，但清洗、抽取、融合和分析的难度也越高。

3. 大数据通常有哪几个特征?

大数据通常具有 **5V** 特征：

1. **Volume（大体量）**：数据规模巨大，可达数百 TB、PB 甚至 EB 级，传统单机和关系数据库难以承担其存储与计算任务。
2. **Variety（多样性）**：数据来源和格式丰富，包括结构化数据、半结构化数据与非结构化数据，如交易记录、文本、图片、视频和传感器数据等。
3. **Velocity（高速/时效性）**：数据产生、传输和处理速度快，许多应用需要流式、实时或近实时处理；对某些业务而言，不能及时得到结果便失去价值。
4. **Veracity（真实性/准确性）**：数据可能包含噪声、缺失、重复或错误，需要通过清洗、校验和质量控制保证分析结果具有可信度。
5. **Value（价值）**：海量数据的价值密度往往较低，需运用分析与挖掘技术从中提炼稀疏但重要的信息，进而转化为商业价值或决策价值。

4. 请简述金融数据的核心属性

金融数据是经济活动的量化记录，其核心属性包括以下三点：

1. **时间序列性**：金融数据会随时间持续变化，例如股票价格、成交量和利率曲线。它通常同时表现出趋势性、周期性和随机性，因此分析时需关注时间顺序、滞后效应和动态变化。
2. **高维度性**：金融市场涉及资产价格、交易量、持仓、信用风险指标、宏观经济变量和市场情绪等大量变量，且各变量之间相互影响，形成多维、复杂的数据体系。
3. **非线性关系**：金融变量之间往往不是简单的线性对应关系。市场波动、风险传导和投资者行为会使变量关系呈现阈值效应、突变或复杂联动，因而常需使用非线性建模、机器学习等方法进行分析。

此外，金融数据还常具有实时性、高频性、结构化与非结构化并存的特点。例如市场行情和交易流属于高频实时数据，财务报表和宏观指标可作为历史数据，新闻与社交媒体内容则需要借助自然语言处理提取其信息价值。

参考课件：`00 Preview.pdf` 、 `01 Big Data.pdf` 。