作业 3

姓名：韦煜嘉　　学号：241275037

1. MapReduce 是面向大规模数据并行处理的，具有哪三个层面的含义？

MapReduce 同时具有以下三个层面的含义：

(1) **基于集群的高性能并行计算平台。**它以大量普通服务器组成集群，汇聚计算、存储和网络资源，使海量数据能够被分片后在多台机器上并行处理，并可通过增加节点实现横向扩展。

(2) **并行计算与运行软件框架。**运行时负责输入切分、任务调度、数据分发、Shuffle、负载均衡、状态监控和故障恢复等工作，从而向程序员屏蔽分布式系统的复杂细节。

(3) **并行程序设计模型与方法。**程序员主要编写 `Map` 和 `Reduce` 两个函数，分别完成数据的映射变换和按键归并；系统依据“分而治之”的思想自动把计算扩展到整个集群。

2. Google MapReduce 中 Master-Worker 模式是如何工作的？

一次 MapReduce 作业通常被划分为 M 个 Map 任务和 R 个 Reduce 任务。用户程序启动后，一个进程充当 Master，其余进程作为 Worker。其工作过程如下：

1. **切分与分配。**MapReduce 库将输入文件切成 M 个分片。Master 维护任务状态，并把尚未执行的 Map 或 Reduce 任务分配给空闲 Worker。分配 Map 任务时尽量选择保存该数据副本的机器，以利用数据本地性、减少网络传输。
2. **Map 阶段。**Map Worker 读取输入分片，将记录解析为键值对并调用用户的 `Map` 函数。产生的中间键值对先缓存在内存中，再按分区函数划分为 R 份并写入本地磁盘，文件位置随后报告给 Master。
3. **Shuffle 与排序。**Master 将中间文件的位置通知 Reduce Worker。Reduce Worker 通过网络从各 Map Worker 拉取属于自己的分区，对中间键进行归并排序，并把相同键的值组合成一组。
4. **Reduce 与输出。**Reduce Worker 对每个中间键及其值集合调用用户的 `Reduce` 函数，并把结果写入分布式文件系统，最终通常形成 R 个输出文件。
5. **完成与容错。**Master 周期性探测 Worker。若 Worker 失效，未完成任务会被重新调度；已完成的 Map 任务也可能重做，因为其中间结果保存在失效机器的本地磁盘上。所有任务完成后，Master 通知用户程序返回。

3. 简述 GFS 的基本架构和数据访问过程。

GFS 采用单 Master、多 Chunkserver 和多个 Client 的结构。文件被划分为固定大小的 Chunk，经典设计中每个 Chunk 为 64 MB。每个 Chunk 具有全局唯一的句柄，并默认保存多个副本，通常为 3 份。

Master 维护文件名空间、文件到 Chunk 的映射、Chunk 副本位置、版本号和租约等元数据，并通过操作日志和检查点保证元数据可恢复。Chunkserver 在本地磁盘上保存实际数据块，根据句柄和块内偏移提供读写服务，并定期向 Master 汇报状态。Client 内嵌 GFS 库。Master 只参与元数据查询，实际数据直接在 Client 与 Chunkserver 之间传输，因此不会成为数据通路的瓶颈。

读取数据时，Client 根据文件名和字节偏移计算 Chunk 序号，向 Master 查询对应的 Chunk 句柄及副本位置，并缓存这些元数据；随后选择一个较近的副本，携带 Chunk 句柄和块内偏移向 Chunkserver 发起读取，数据由 Chunkserver 直接返回。

写入数据时，Client 先向 Master 查询拥有租约的主副本和各次副本，然后以流水线方式把数据推送到所有副本。数据到达后，Client 再向主副本发送写请求。主副本为多个写操作确定统一顺序，并要求各次副本按相同顺序执行。次副本完成后逐级确认，最后由主副本向 Client 返回结果。若部分副本失败，Client 会重试，Master 则处理过期副本并安排重新复制。

4. 简述 Bigtable 的数据模型和数据存储格式。

Bigtable 是一个稀疏、分布式、持久化、按行键有序的多维映射，其数据模型可表示为：

```
(row:string, column:string, time:int64) -> string
```

行键是任意字符串，并按字典序排列。同一行内的读写具有原子性，连续的行键范围构成 Tablet。列名由“列族: 限定符”组成，列族必须预先声明，是访问控制、压缩和物理组织的基本单位；限定符可以动态增加。表是稀疏的，未写入的单元格不占空间。一个单元格可以保存多个版本，版本由 64 位时间戳区分，并按时间戳降序排列。系统可以通过保留最近若干版本或设置生存时间来回收旧数据。

在存储方面，一张表按连续行键范围划分为多个 Tablet，并由 Tablet Server 管理。写入首先追加到 Commit Log 以保证故障恢复，然后进入内存中的有序 Memtable。当 Memtable 达到阈值时，会被写成不可变、按键排序的 SSTable；后台压缩再把多个 SSTable 合并，清理已删除或过期的数据。

SSTable 是 Bigtable 的核心磁盘格式，内部保存按键排序的键值记录和块索引，适合顺序扫描及按键定位。读取时，Tablet Server 综合查询 Memtable 与若干 SSTable，并借助缓存、块索引和 Bloom Filter 减少磁盘访问。系统使用 Chubby 进行选主与协调，并通过根 Tablet 和元数据表定位用户 Tablet 所在的服务器。